

앤스로픽, Mythos급 프런티어 모델 Claude Fable 5·Mythos 5 공개 — SOTA 성능과 이중용도 안전장치 동시 구현

Anthropic

Claude Fable 5

Claude Mythos 5

Opus 4.8

SWE-bench Pro

80.3%

SWE-bench Pro · 에이전트 코딩 SOTA

\$10 / \$50

입력/출력 100만 토큰 (Opus 4.8의 2배)

78.0%

ExploitBench · Mythos 5 사이버 역량

<5%

안전장치 분류기 작동 세션 비율

KEYNOTE

- 앤스로픽은 Opus 4.8 상위에 신규 'Mythos급' 모델을 신설, 일반 공개용 Claude Fable 5와 제한판 Claude Mythos 5를 동시 출시했다.
- Fable 5는 SWE-bench Pro 80.3%, Cognition FrontierCode Diamond 29.3% 등 주요 벤치마크에서 SOTA를 기록하며, GPT-5.5·Gemini 3.1 Pro를 상회한다.
- Mythos 5는 ExploitBench 78.0%로 사이버보안·생물추론에서 세계 최고 성능을 보이나, 이중용도 위험 방지를 위해 접근이 엄격히 제한된다.
- Fable 5의 가격은 입력 100만 토큰당 \$10·출력 \$50로 Opus 4.8의 2배, Mythos Preview의 절반 이하이며, 안전장치 분류기가 전체 세션의 5% 미만에서만 작동한다.

① 개요 Overview

앤스로픽은 2026년 6월 9일, 기존 Opus 계층을 넘어서는 신규 'Mythos급' 프런티어 모델 Claude Fable 5와 Claude Mythos 5를 공개했다. Fable 5는 안전장치를 적용해 일반에 개방되는 최초의 Mythos급 모델로, 소프트웨어 엔지니어링·비전·과학연구 등 거의 모든 주요 벤치마크에서 SOTA를 달성했다. Mythos 5는 동일한 기반 모델에서 안전장치를 해제해, 인가된 사이버보안·생물 연구 전문가에게만 제공된다.

SWE-bench Pro — 에이전트 코딩 정확도

% · 높을수록 우수 · 출처: Anthropic / Vellum 벤치마크

Claude Fable 5	80.3
Mythos Preview	77.8
Opus 4.8	69.2
GPT-5.5	58.6
Gemini 3.1 Pro	54.2

② 주요내용 Deep Dive

모델 계층 및 접근 정책: 앤스로픽은 기존 Opus 4.8 위에 신규 'Mythos급 (Mythos-class)' 계층을 신설했다. Claude Fable 5는 이 Mythos급 모델을 안전장치와 함께 일반에 공개한 최초의 사례이며, Claude Mythos 5는 동일한 기반에서 일부 안전장치를 해제해 인가된 전문가(사이버보안, 인프라, 생물 연구자)에게만 제공된다. Fable 5는 Claude API(모델 ID claude-fable-5)와 엔터프라이즈 플랜에서 즉시 사용 가능하며, Pro·Max·Team·시트형 구독에는 6월 22일까지 추가 비용 없이 포함된다. 6월 23일부터는 사용 크레딧이 필요하다.



Claude Fable 5·Mythos 5 공개 발표 이미지 · 출처: Anthropic

성능 벤치마크: Fable 5는 SWE-bench Pro(에이전트 코딩)에서 80.3%로 Mythos Preview(77.8%), Opus 4.8(69.2%), GPT-5.5(58.6%), Gemini 3.1 Pro(54.2%)를 모두 상회한다. Cognition FrontierCode(프로덕션 코드 표준 준수) Diamond 분할에서 29.3%로 Opus 4.8(13.4%)의 2배 이상, GPT-5.5(5.7%)를 크게 앞선다. GDP.pdf(도구 없는 비전 추론)에서는 29.8%로 GPT-5.5(24.9%), Opus 4.8(22.5%), Gemini 3.1 Pro(16.7%)를 능가한다. Hebbia Finance Benchmark에서는 90% 이상을 달성했으며, FrontierCode에서도 최고점을 기록했다.

이중용도(dual-use)·안전장치: Mythos 5는 ExploitBench(사이버 공격역량 캡처)에서 78.0%로 Mythos Preview(69.0%), Opus 4.8(40.0%), GPT-5.5(34.0%)를 압도한다. BioMysteryBench(고난도 생물 추론)에서도 46.1%로 Opus 4.8(40.0%), Mythos Preview(29.6%)를 앞선다. Fable 5에는 사이버보안·생물/화학·증류(distillation) 3개 영역 분류기가 내장되어 민감 질의가 탐지되면 Claude Opus 4.8로 우회 처리된다. 이 안전장치는 전체 세션의 5% 미만에서만 트리거된다.

장기 자율성·비전·과학: Fable 5는 수백만 토큰(millions of tokens)에 걸친 장기 자율 작업이 가능하며, 작업 중 메모를 남겨 자기 작업을 개선하는 메커니즘을 갖췄다. 메모리 의존 과제에서 3배의 성능 향상을 보인다. 비전 영역에서는 화면 캡처에서 정밀 수치 추출, 코드 재구성, 보조도구 없이 게임 완수 등 고난도 작업을 수행한다. 과학 분야에서는 단백질 설계 워크플로를 10배 가속하고, 분자생물학 신규 가설 생성, 유전체 연구 자율 수행 등에서 두드러진다.

가격·데이터 정책: Fable 5의 가격은 입력 100만 토큰당 \$10, 출력 \$50로 Opus 4.8(\$5/\$25)의 정확히 2배이며, Mythos Preview의 절반 이하다. Mythos급 모델은 30일간 데이터 보관 정책을 적용하며, 안전 모니터링 데이터는 모델 학습에 사용하지 않는다.

- Cognition FrontierCode Diamond: Fable 5 **29.3%** > Opus 4.8 13.4% > GPT-5.5 5.7%
- BioMysteryBench(생물 추론): Mythos 5 **46.1%** > Opus 4.8 40.0% > Mythos Preview 29.6%
- 장기 자율성: 수백만 토큰 · 메모리 의존 과제 3배 향상 · 단백질 설계 10배 가속

③ 시사점 Implications

연구·개발 관점

Claude Fable 5·Mythos 5의 등장은 **프런티어 AI의 성능·안전성·접근성 지형을 크게 바꾼다**. 첫째, SWE-bench Pro·FrontierCode·비전·과학 등 주요 벤치마크에서 기존 Opus 4.8, GPT-5.5, Gemini 3.1 Pro를 모두 상회하는 SOTA 성능은, 실험적 연구·코드 자동화·복합 추론·생물정보학 등 다양한 분야에서 새로운 실험 설계와 워크플로 혁신을 가능하게 한다. 둘째, Mythos 5의 ExploitBench·BioMysteryBench 최고 기록은 사이버보안·생물학 이중용도(dual-use) 위험이 현실화되는 국면에서, 안전장치 분류기와 접근 제한 정책이 프런티어 모델의 사회적 수용성과 규제 대응의 핵심 변수임을 보여준다. 셋째, Fable 5의 가격 정책(입력·출력 모두 Opus 4.8의 2배)은 연구·산업 현장에서 프런티어 프리미엄의 비용-효과 분석을 요구한다. **한계 및 미해결 쟁점**으로, 안전장치의 자체 벤치마크 검증 신뢰성, Mythos 5의 제한적 접근에 따른 재현성·공정성 논란, 30일 데이터 보관의 프라이버시 문제 등이 있다. **향후 관전 포인트**는 (1) Mythos 5의 생물 연구자 신뢰 접근 프로그램 구체화, (2) 미국·EU의 프런티어 모델 규제(자율 검증·실천강령)와의 정합성, (3) 경쟁사(OpenAI·Google)의 대응과 프런티어 추론 수요가 AI 인프라·HBM4 반도체 공급망에 미칠 파급효과다.

④ 출처 · 더 읽을거리 Sources

- Anthropic 공식 발표 — 1차 원천
- Claude Fable 5 & Mythos 5 Full Benchmark Breakdown (Vellum) — 해설·벤치마크 분석
- Claude Fable 5 brings Mythos to the masses (Tom's Hardware) — 외신 보도
- 백악관 '첨단 AI 혁신·안보 촉진' 행정명령 (whitehouse.gov) — 정책 맥락
- EU AI법 8월 2일 본격 적용 — GPAI 실천강령 (artificialintelligenceact.eu) — 규제 맥락

그 외 주목 단신

- 구글 딥마인드, 'Gemini 3.5 Live Translate'로 거의 실시간 자연 음성 번역
- 오픈AI, EU AI 콘텐츠 투명성 실천강령 지지 (출처표기·AI 생성물 식별)