

앤스로픽, Opus 상위 '프런티어' 모델 Claude Fable 5·Mythos 5 공개 — 거의 전 벤치마크 SOTA, 사이버·생물 이중용도 안전장치 동반

Anthropic

model

연구·개발(주)+정책(보조) 관점

TL;DR

- 앤스로픽이 6월 9일 기존 Opus 계층 위에 새로 신설한 'Mythos급' 모델을 처음 일반 공개 — 안전장치를 적용한 일반판 Claude Fable 5와, 동일 기반에서 안전장치를 해제해 인가된 방어 전문가에게만 주는 제한판 Claude Mythos 5를 동시 출시했다.
- Fable 5는 거의 모든 테스트 벤치마크에서 SOTA를 표방한다 — 에이전트 코딩 SWE-bench Pro 80.3%(Opus 4.8 69.2%·GPT-5.5 58.6%·Gemini 3.1 Pro 54.2% 상회), 비전 추론·프로덕션 코드(FrontierCode)에서도 프런티어 최고점.
- Mythos 5는 안전장치를 푼 상태에서 사이버 공격역량(ExploitBench 78.0%, Opus 4.8의 거의 2배)·생물 추론(BioMysteryBench 46.1%)을 드러내며, 일반판은 사이버·생물/화학·증류 3개 분류기로 민감 질의를 Opus 4.8로 우회(전 세션의 5% 미만 트리거)한다.
- 프런티어 역량의 대중 개방과 이중용도 위험 차단을 동시에 설계한 사례로, '커버드 프런티어 모델' 행정명령(6/2)·EU AI법 GPAI 실천강령(8/2 적용) 흐름과 직결된다.

① 무엇이 — 사실관계

앤스로픽은 2026년 6월 9일, 기존 Opus 계층 위에 새로 위치하는 'Mythos급(Mythos-class)' 모델을 처음 일반 출시했다. 같은 기반 모델에서 ▲안전장치를 적용해 누구나 쓸 수 있게 한 일반판 Claude Fable 5와 ▲일부 안전장치를 해제해 인가된 사이버 방어·인프라·연구 전문가에게만 제공하는 제한판 Claude Mythos 5를 동시에 내놨다. 앤스로픽은 Fable 5를 "거의 모든 테스트 벤치마크에서 SOTA"로 규정하며 소프트웨어 엔지니어링·지식노동·비전·과학연구에서 두각을 보인다고 밝혔다. 가격은 입력 100만 토큰당 \$10·출력 \$50로, 직전 Opus 4.8(\$5/\$25)의 정확히 2배다. Fable 5는 출시 즉시 Claude API(모델 ID claude-fable-5)와 소비량 기반 엔터프라이즈 플랜에서 제공되며, Pro·Max·Team·시트형 엔터프라이즈 구독에는 6월 22일까지 추가비용 없이 포함되고 6월 23일부터는 사용 크레딧이 필요하다. Mythos 5는 사이버보안 파트너십 'Project Glasswing' 대상으로 우선 개방되고, 생물 연구자용 신뢰 접근 프로그램이 곧 출범한다. (가격·안전장치 트리거율·계층 정의는 앤스로픽 공식 발표로 직접 확인했다.)

② 기술 핵심

모델 계층. Mythos급은 Opus급 위에 신설된 상위 티어다. Fable 5는 안전장치를 적용한 일반판, Mythos 5는 동일 기반 모델에서 안전장치를 해제한 제한판으로, 두 모델의 성능 격차는 사실상 안전장치(분류기 우회)의 효과를 드러낸다.

- SWE-bench Pro(에이전트 코딩): Fable 5 80.3% > Mythos Preview 77.8% > Opus 4.8 69.2% > GPT-5.5 58.6% > Gemini 3.1 Pro 54.2%.
- Cognition FrontierCode(프로덕션 코드 표준 준수) 최난도 Diamond 분할: Fable 5 29.3% — Opus 4.8 13.4%의 2배 이상, GPT-5.5 5.7%를 크게 상회.
- GDP.pdf(도구 없는 비전 추론): Fable 5 29.8% > GPT-5.5 24.9% > Opus 4.8 22.5% > Gemini 3.1 Pro 16.7%. Hebbia 금융 벤치마크는 "전 모델 최고점".
- ExploitBench(사이버 공격역량): 안전장치를 푼 Mythos 5 78.0% > Mythos Preview 69.0% > Opus 4.8 40.0% > GPT-5.5 34.0% — Opus 4.8의 거의 2배.
- BioMysteryBench(고난도 생물 추론): Mythos 5 46.1% > Opus 4.8 40.0% > Mythos Preview 29.6%.

안전장치 메커니즘. 일반판 Fable 5는 사이버보안·생물/화학·증류(distillation) 3개 영역 분류기로 민감 질의를 탐지해 해당 응답만 Claude Opus 4.8로 우회한다. 트리거는 전체 세션의 5% 미만이며, 위 사이버·생물 수치는 우회가 적용되지 않은 Mythos 5의 실제 역량 차이를 보여준다(Vellum 분석). 장기 자율성: 수백만 토큰에 걸친 자율 작동과 작업 중 메모 남기기를 지원해 메모리 의존 과제에서 3배 성능 향상을 보고했다. 비전: 화면 캡처에서 정밀 수치 추출·코드 재구성, 보조도구 없이 비전만으로 게임 완수. 과학: 단백질 설계 워크플로 10배 가속, 분자생물학 신규 가설 생성. Mythos급은 30일 데이터 보관, 안전 모니터링 데이터로 모델 학습은 하지 않는다.

③ 맥락·배경

직전 세대는 Claude Opus 4.8(\$5/\$25)였고, Mythos급은 그동안 'Mythos Preview'로만 제한 노출됐다. Fable 5는 그 Mythos급을 안전장치와 함께 처음 대중에 푼 것으로, '프런티어 역량의 일반 개방 + 이중용도 위험의 분류기 차단'이라는 앤스로픽 특유의 출시 전략을 보여준다. 경쟁 구도에서는 코딩(SWE-bench Pro)·비전(GDP.pdf)·프로덕션 코드(FrontierCode) 전반에서 OpenAI GPT-5.5, Google Gemini 3.1 Pro 대비 우위를 주장한다. 같은 주 DeepMind는 확산 기반 오픈모델 DiffusionGemma를, OpenAI는 비공개

IPO 신청과 EU 투명성 강령 지지로 맞불을 놓아 프런티어 3강의 경쟁이 제품·자본·규제 전선에서 동시 전개되는 국면이다(앤스로픽 9,650억 달러 평가로 IPO 신청). 한국 공급망과의 직접 연관은 약하나, 프런티어 추론 수요 급증이 HBM4·AI 인프라(엔비디아 Vera Rubin) 수요로 이어지는 거시 연결고리가 있다.

④ 합의 분석

연구·개발 관점 (주)

연구자에게 핵심은 '동일 기반 모델 + 안전장치 on/off'라는 통제 비교가 처음으로 공개 벤치마크에 드러났다는 점이다. Fable 5와 Mythos 5의 사이버(ExploitBench 40%p 차)·생물(BioMysteryBench 격차)은 분류기 우회가 위험 역량을 얼마나 깎는지를 정량 화해, 안전장치의 비용·효과를 재현 가능한 형태로 논의할 단초를 준다. SWE-bench Pro 80.3%·FrontierCode Diamond 29.3%는 에이전트형 장기 코딩(수백만 토큰 자율 작동·작업 중 메모)이 단발 추론을 넘어 '지속 작업' 평가로 옮겨가고 있음을 시사하며, 후속 연구는 메모리 의존 과제(3배 향상 주장)의 독립 재현·오염 통제에 집중해야 한다. 다만 SWE-bench Pro·FrontierCode·GDP.pdf·ExploitBench 등 상당수가 자체/파트너 벤치마크여서, 표준 공개셋(SWE-bench Verified 등) 대비 검증과 컨테이너화 점검이 연구 신뢰성의 관건이다. 비전·과학(단백질 설계 10배) 역량은 멀티모달 에이전트와 자동 가설 생성 연구의 새 베이스라인이 될 수 있다.

정책 관점 (보조)

정책적으로는 Mythos 5가 '이중용도 프런티어 모델'의 교과서적 사례다. 안전장치를 켜 모델이 ExploitBench 78%·고난도 생물 추론 46%를 보인다는 사실은, 6/2 행정명령의 '커버드 프런티어 모델' 식별·자율 안보 테스트 프레임워크와 EU AI법 8/2 GPAI 의무가 겨냥하는 위험 범주와 정확히 겹친다. 앤스로픽이 일반 개방판에 분류기 우회를 걸고 제한판은 정부·인프라 파트너(Project Glasswing)로만 쏜 것은, 기업 자율 거버넌스가 사실상 '접근 통제 = 규제 대체재'로 기능하기 시작했음을 보여준다. 정책자는 ① 분류기 트리거율·우회 정확도 같은 안전장치 성능의 외부 감사 가능성, ② '인가된 방어자' 자격·공급망 통제에 표준화, ③ EU GPAI 실천강령 서명(약 24개 제공자)이 준수 입증 수단으로 충분한지를 점검해야 한다. 30일 데이터 보관·학습 미사용 정책은 프라이버시·증류 방지 측면의 참고 기준이 된다.

⑤ 한계·미해결 쟁점·전망

수치 대부분이 앤스로픽 자체 또는 파트너(Cognition·Hebbia) 벤치마크라 독립 재현·오염 통제가 전제돼야 한다 — 본 브리프는 앤스로픽 공식 발표(가격·안전장치·계층)와 Vellum의 벤치마크 정리로 교차검증했으나, 표준 공개셋에서의 동일 우위는 아직 미확인이다. '세계 최강 사이버보안 역량' 표방과 안전장치 해제판의 동시 존재는, 분류기가 우회·탈옥에 견디는지가 핵심 미해결 쟁점이다(트리거율 5%의 분모·오탐/미탐 비율 비공개). 가격이 Opus 4.8의 2배라 일상 사용에서의 비용·성능 트레이드오프가 채택 변수이며, 구독 무료 포함은 6/22까지로 한시적이다. 관련 포인트: ① 독립기관의 안전장치·벤치마크 재현, ② EU AI법 8/2 적용·행정명령 하 '커버드 모델' 지정 여부, ③ DiffusionGemma(오픈·확산)·GPT-5.5와의 실사용 비교, ④ Project Glasswing·생물 신뢰 접근 프로그램의 자격·감사 체계.

⑥ 출처 · 더 읽을거리

- [Claude Fable 5 and Claude Mythos 5 \(Anthropic 공식 발표\)](#) — 1차 원천, 가격·안전장치·계층 직접 확인
- [Claude Fable 5 & Mythos 5 Full Benchmark Breakdown \(Vellum\)](#) — 벤치마크 수치 교차검증
- [Claude Fable 5 brings Mythos to the masses \(Tom's Hardware\)](#) — 외신 보도·대중 개방 프레임
- 백악관 '첨단 AI 혁신·안보 촉진' 행정명령 (6/2) — 커버드 프런티어 모델 정책
- EU AI법 이행 타임라인 (8/2 GPAI 적용) — GPAI 실천강령 규제 맥락

그 외 주목 단신

- [구글 딥마인드, 확산 기반 오픈소스 'DiffusionGemma' 공개 \(텍스트 생성 4배 가속, Apache 2.0\)](#)
- [독일 뉴라로보틱스, 휴머노이드 '피지컬 AI'에 최대 14억 달러 유치 \(엔비디아·아마존·테더, 기업가치 ~70억 달러\)](#)
- [엔비디아 'Vera Rubin' 양산 — HBM4 공급사로 삼성·SK하이닉스·마이크론 지정](#)