

앤스로픽, Claude Fable 5·Mythos 5 공개

Opus 상위 Mythos급 일반·제한판 동시 출시

AnthropicClaude Fable 5Claude Mythos 5Mythos급Project Glasswing

80.3%
SWE-bench Pro 에이전트 코딩

\$10/\$50
입력/출력 100만 토큰 가격

78.0%
Mythos 5 ExploitBench

<5%
안전 분류기 트리거 세션 비중

한눈에 보기


- Anthropic은 2026년 6월 9일 기존 Opus급 위에 새 ‘Mythos급’을 두고 Claude Fable 5(안전장치 적용 일반판)와 Claude Mythos 5(동일 기반·일부 안전장치 해제 제한판)를 공개했다.
- 자체 보고 기준 Fable 5는 SWE-bench Pro에서 80.3%로 Opus 4.8 69.2%·GPT-5.5 58.6%를 앞섰다 (공식 발표 수치·독립 재현 전).
- Mythos 5는 ExploitBench 78.0%·BioMysteryBench 46.1%로 보고됐고, 이중용도 위험 때문에 Project Glasswing 전문가에게 우선 제공된다.
- Fable 5 가격은 입력/출력 100만 토큰당 \$10/\$50로 Opus 4.8(\$5/\$25)의 2배다. 구독 포함은 6월 22일 까지, 23일부터 사용 크레딧 필요.

① 무엇이 달라졌나

Anthropic의 이번 발표는 단일 신모델 출시라기보다 모델 계층과 접근정책을 함께 재편한 사례다. 회사는 기존 Opus급 위에 ‘Mythos급’을 신설하고, 같은 기반 모델을 안전장치가 적용된 Claude Fable 5와 제한 접근형 Claude Mythos 5로 나눴다. Fable 5는 그동안 제한적으로 노출된 Mythos Preview 계열 역량을 일반 API와 엔터프라이즈 환경에 개방하는 성격을 갖는다. 동시에 사이버·생물 영역의 고위험 역량은 별도 분류기와 접근통제로 관리하겠다는 출시 전략을 제시했다.

SWE-bench Pro — 에이전트 코딩

% · 높을수록 우수 · Anthropic 자체 보고



② 사실과 쟁점

Anthropic은 2026년 6월 9일 공식 블로그에서 Claude Fable 5와 Claude Mythos 5를 공개했다. 두 모델은 기존 Opus급 위에 신설된 Mythos급에 속하며 동일한 기반 모델을 공유한다. 차이는 접근정책과 안전장치다. Fable 5는 안전장치를 적용한 일반 공개판이고, Mythos 5는 일부 안전장치를 해제해 인가된 사이버 방어·인프라·연구 전문가에게만 제공하는 제한판이다. Anthropic은 Fable 5가 소프트웨어 엔지니어링·지식노동·비전·과학연구에서 ‘거의 모든 벤치마크에서 SOTA’라고 표방했으나, 아래 수치는 모두 공식 발표 기반의 자체 보고로 독립 재현 전이라는 점을 구분해야 한다.



Claude Fable 5와 Claude Mythos 5 공개 자료 이미지, 출처: Anthropic

코딩에서 자체 보고 수치가 가장 구체적이다. **SWE-bench Pro** 에이전트 코딩에서 Fable 5는 80.3%로 Mythos Preview 77.8%, Opus 4.8 69.2%, GPT-5.5 58.6%, Gemini 3.1 Pro 54.2%를 앞섰다. **Cognition FrontierCode**에서는 프런티어 모델 중 최고로 보고됐고 최난도 **Diamond** 분할에서 29.3%(Opus 4.8 13.4%의 2배 이상, GPT-5.5 5.7%)를 기록했다. Hebbia Finance Benchmark는 90%+를 발표했으나 세부 항목·재현 여부는 공개되지 않았다.

비전·과학·장기 자율성 주장도 함께 제시됐다. 도구 없는 비전 추론 **GDP.pdf**에서 Fable 5는 29.8%로 GPT-5.5 24.9%, Opus 4.8 22.5%, Gemini 3.1 Pro 16.7%를 앞섰다. Anthropic은 화면 캡처에서 수치 추출·코드 재구성, 보조도구 없는 게임 완수, 단백질 설계 10배 가속, 수백만 토큰 자율 작동과 메모리 의존 과제 3배 향상을 들었으나, 과제 정의·재현 절차·외부 평가 조건은 공개되지 않았다.

제한판 **Claude Mythos 5**의 핵심 쟁점은 사이버·생물 이중용도 역량이다. Anthropic 공식 발표 기준 **ExploitBench**에서 Mythos 5는 78.0%(Mythos Preview 69.0%, Opus 4.8 40.0%, GPT-5.5 34.0%)로 ‘세계 최강 사이버보안 역량’으로 표방됐으나 이는 자체 발표 표현이다. 고난도 생물 추론 **BioMysteryBench**에서는 46.1%(Opus 4.8 40.0%, Mythos Preview 29.6%)로 보고됐다. 이 때문에 Mythos 5는 사이버보안 파트너십 **Project Glasswing** 대상에 우선 개방되고, 생물 연구자용 신뢰 접근 프로그램이 곧 출범한다.

상용 조건과 안전장치도 계층화의 일부다. Fable 5는 모델 ID **claude-fable-5**로 Claude API와 소비량 기반 엔터프라이즈 플랜에 즉시 제공되며, 가격은 입력/출력 100만 토큰당 **\$10/\$50**로 Opus 4.8(\$5/\$25)의 2배다. Pro·Max·Team·시트형 구독에는 6월 22일까지 추가비용 없이 포함되고 6월 23일부터 사용 크레딧이 필요하다. 안전 면에서는 사이버보안·생물/화학·증류 3개 분류기가 민감 질의를 **Opus 4.8**로 라우팅(전체 세션의 5% 미만 트리거)하며, Mythos급 데이터는 30일 보관·안전 모니터링 데이터는 학습에 쓰지 않는다고 밝혔다.

- **FrontierCode Diamond:** Fable 5 29.3% · Opus 4.8 13.4% · GPT-5.5 5.7% (Anthropic 보고).
- **GDP.pdf(비전):** Fable 5 29.8% · GPT-5.5 24.9% · Opus 4.8 22.5% · Gemini 3.1 Pro 16.7%.
- **BioMysteryBench:** Mythos 5 46.1% · Opus 4.8 40.0% · Mythos Preview 29.6%.

미해결 쟁점은 세 가지다. 첫째, 성능 수치 대부분이 자체 발표라 동일 프롬프트·도구·예산 조건의 독립 재현이 필요하다. 둘째, 동일 기반 모델이라도 안전장치가 실사용 성능과 위험 프로파일을 어떻게 바꾸는지 공개 수치만으로는 판단하기 어렵다. 셋째, 장기 자율성·작업 중 메모·과학 워크플로 가속은 연구 자동화에 직접 영향을 주지만 실패 모드·감사 가능성 자료는 공개되지 않았다.

③ 왜 중요한가

연구·개발 관점에서 이번 발표는 프런티어 모델의 비교 축을 단순 정확도에서 장기 자율성·비전 작업·과학 워크플로와 안전장치가 결합된 운영 조건으로 옮긴다. 자체 보고 기준 Fable 5가 SWE-bench Pro 80.3%, GDP.pdf 29.8%, FrontierCode Diamond 29.3%를 제시한 만큼, 개발자는 성능뿐 아니라 가격(\$10/\$50)·크레딧 정책·분류기 라우팅 조건을 함께 따져야 한다. 정책 관점에서는 Mythos 5의 ExploitBench 78.0%·BioMysteryBench 46.1%가 공개됐다는 사실 자체가 고성능 모델의 이중용도 접근통제를 구체적 제품 설계 문제로 만든다. Anthropic은 Project Glasswing·3개 분류기·30일 보관·모니터링 데이터 비학습을 제시했으나 분류기 오탐·미탐, 우회 처리, 제한 접근 검증 기준은 확인이 필요하다. 관련 포인트는 독립 벤치마크 재현 여부, 공개 사용에서 분류기 트리거가 실제 5% 미만으로 유지되는지, 제한 접근이 생산성과 위험을 어떻게 동시에 관리하는지다.

④ 출처

- Anthropic
- Claude Fable 5 & Mythos 5 Full Benchmark Breakdown (Vellum)
- Claude Fable 5 brings Mythos to the masses (Tom's Hardware)
- Claude Fable 5 vs GPT-5.5 vs Gemini 3.1 Pro 비교 (Lushbinary)
- Following Anthropic, OpenAI files confidentially for IPO (TechCrunch·CNBC)
- 백악관 '첨단 AI 혁신·안보 촉진' 행정명령 — 프런티어 모델 자율 검증 (whitehouse.gov)
- EU AI법 8월 2일 본격 적용 — 고위험 의무·GPAI 실천강령 (artificialintelligenceact.eu)