

문샷 AI, Kimi K2.7-Code 공개

1T MoE 오픈웨이트 코딩 모델

Moonshot AI

Kimi K2.7-Code

K2.6

MCP Mark Verified

Modified MIT

1T / 32B

총파라미터 / 토큰당 활성 파라미터

256K / 595GB

컨텍스트 길이 / 가중치 용량

62.0

Kimi Code Bench v2 자체보고 점수

약 30%

K2.6 대비 thinking 토큰 절감

KEYNOTE

- Moonshot AI는 2026년 6월 12일 Kimi K2.7-Code를 Kimi 플랫폼 API와 Hugging Face 모델카드로 공개했다. 모델은 1T 총파라미터, 토큰당 활성 32B의 MoE 구조이며 가중치 약 595GB를 Modified MIT 라이선스로 제공한다.
- Kimi K2.7-Code는 직전 K2.6의 1T MoE 아키텍처를 유지하되 코딩·에이전트 작업에 특화된 릴리스다. 문샷 자체 보고 기준 Kimi Code Bench v2는 50.9에서 62.0으로 올라 개선폭은 +21.8%다.
- 경쟁 모델 비교에서 문샷이 제시한 수치상 Kimi K2.7-Code는 Kimi Code Bench v2와 Program Bench에서 Claude Opus 4.8·GPT-4.5보다 낮다. 다만 도구호출 지표인 MCP Mark Verified는 81.1로, 문샷 제시 Opus 4.8 수치 76.4를 상회한다.
- 핵심 한계는 검증 상태다. dossier 기준 6월 12일 시점 SWE-Bench Pro·Terminal-Bench·Aider 등 독립 재현 결과는 미제출·보류이며, 성능 수치는 모두 Moonshot AI 자체보고로 봐야 한다.

① 개요

Moonshot AI가 코딩·에이전트 특화 모델 Kimi K2.7-Code를 공개하고, Kimi 플랫폼 API와 Hugging Face 오픈웨이트 배포를 동시에 시작했다. 이 모델은 K2.6의 1조 파라미터 MoE 기반을 유지하면서 장기 호흡 소프트웨어 엔지니어링과 도구호출 능력 개선을 목표로 한 점진적 특화 릴리스로 정리된다. 공개 범위는 가중치 약 595GB, 256K 토큰 컨텍스트, Modified MIT 라이선스를 포함하며 자가호스팅과 상업적 활용 가능성을 전면에 둔다. 다만 벤치마크 성능과 경쟁 모델 대비 우위 주장은 현재 Moonshot AI 자체보고 단계이며 독립 재현 전이라는 점이 해석의 전제다.

Kimi Code Bench v2 — 문샷 자체보고 비교

점수 · 높을수록 우수 · 독립 검증 전

Kimi K2.7-Code	62.0
Claude Opus 4.8	67.4
GPT-4.5	69.0

② 주요내용

Moonshot AI는 2026년 6월 12일 Kimi K2.7-Code를 공개했다. 1차 출처는 Hugging Face의 공식 모델카드이며, 같은 날 Kimi 플랫폼 API(kimi.com/code)로 서비스 접근도 열었다. 모델 가중치는 약 595GB 규모로 Hugging Face의 moonshotai/Kimi-K2.7-Code에 공개됐고, 라이선스는 Modified MIT로 제시됐다. dossier에 따르면 이 라이선스는 대규모 상업 배포 시 출처표시 조건을 두며 상업적 이용을 허용한다.

아키텍처는 직전 세대 K2.6과 같은 1조(1T) 총파라미터 Mixture-of-Experts(MoE) 계열이다. 토큰당 활성 파라미터는 32B이며, 384개 전문가 중 8개를 선택하는 구조로 설명돼 있다. 컨텍스트 길이는 256K 토큰이고, 시각 인코더로 MoonViT 400M이 포함된다. 이번 릴리스의 초점은 범용 모델 교체라기보다 장기 호흡(long-horizon) 소프트웨어 엔지니어링과 코딩 에이전트 능력을 강화한 특화 분기다.

Moonshot AI 자체보고 벤치마크에서 K2.7-Code는 K2.6 대비 여러 코딩·에이전트 지표가 개선됐다고 제시됐다. Kimi Code Bench v2는 50.9에서 62.0으로 올라 +21.8% 개선으로 보고됐고, Program Bench는 48.3에서 53.6으로 +11.0% 개선됐다고 발표했다. MLS Bench Lite는 26.7에서 35.1로 +31.5%, Kimi Claw 24/7 Bench는 42.9에서



Kimi 브랜드 로고 배너(모델카드 게재 이미지). 출처: Moonshot AI Hugging Face 모델카드

46.9로 +9.3% 개선됐다는 수치가 제시됐다. 도구호출·MCP 관련 지표에서는 MCP Atlas가 69.4에서 76.0으로 +9.5%, MCP Mark Verified가 72.8에서 81.1로 +11.4% 개선됐다고 문샷은 밝혔다. 이 수치들은 모두 당사자 자체 측정으로, 독립 검증 전 결과로 해석해야 한다.

경쟁 모델 대비 위치는 지표별로 다르게 제시된다. Moonshot AI가 제시한 비교에서 Kimi Code Bench v2는 Kimi K2.7-Code 62.0, Claude Opus 4.8 67.4, GPT-4.5 69.0으로 Kimi가 뒤에 있다. Program Bench도 Kimi K2.7-Code 53.6, Opus 4.8 63.8, GPT-4.5 69.1로 같은 방향이다. MLS Bench Lite에서는 Kimi K2.7-Code 35.1, Opus 4.8 42.8, GPT-4.5 35.5로 제시돼 Kimi가 GPT-4.5와 근접하지만 Opus 4.8에는 낮다. 반면 도구호출 지표인 MCP Mark Verified에서는 Kimi K2.7-Code 81.1, Opus 4.8 76.4로 문샷 자체 수치상 Kimi가 앞서는 것으로 나타난다.

운영 비용 측면에서 문샷은 K2.6 대비 추론(thinking) 토큰 사용량을 약 30% 줄였다고 보고했다. 에이전트형 코딩 작업은 여러 단계의 계획, 도구호출, 파일 수정, 재검토를 반복하기 때문에 thinking 토큰 감소는 동일 작업의 비용 구조에 영향을 줄 수 있다(자연시간 효과는 dossier에 근거가 없어 별도 검증이 필요하다). 다만 API 가격은 공개 시점 기준 TBD로 제시돼 있어, 실제 비용 절감 폭은 Kimi 플랫폼의 과금 구조가 확정돼야 평가할 수 있다. 구독형 Kimi Code의 가격은 dossier 기준 약 \$19/월(Moderato)에서 \$199/월(Vivace) 범위로 제시됐다.

접근 정책 측면에서 Kimi K2.7-Code는 오픈웨이트 배포와 플랫폼형 서비스를 병행한다. 사용자는 Hugging Face에서 전체 가중치를 내려받아 자가호스팅할 수 있고, 동시에 Kimi Code 구독 또는 API를 통해 서비스형으로 접근할 수 있다. 문샷은 장기 자율 코딩 기능을 직전 세대의 '12시간 자율 코딩 런' 계승선상에서 제시하고, 향후 '6x 고속 모드'를 예고했다. 그러나 장기 자율 코딩 성능과 고속 모드의 실제 성능·비용·안정성은 dossier 기준 아직 별도 독립 수치가 없다.

- **모델 규모:** 1T 총파라미터, 토큰당 활성 32B, 384개 전문가 중 8개를 선택하는 MoE.
- **컨텍스트·가중치:** 256K 토큰 컨텍스트, 약 595GB 가중치, MoonViT 400M 포함.
- **라이선스:** Modified MIT 오픈웨이트, 대규모 상업 배포 시 출처표시 조건.
- **K2.6 대비 자체보고 개선:** Kimi Code Bench v2 62.0(+21.8%), Program Bench 53.6(+11.0%), MLS Bench Lite 35.1(+31.5%).
- **도구호출 자체보고:** MCP Atlas 76.0(+9.5%), MCP Mark Verified 81.1(+11.4%).
- **경쟁 비교:** 문샷 제시 Kimi Code Bench v2는 Kimi 62.0, Claude Opus 4.8 67.4, GPT-4.5 69.0이며, MCP Mark Verified는 Kimi 81.1, Opus 4.8 76.4.
- **가격·효율:** Kimi Code 구독은 약 \$19/월~\$199/월, API 가격은 공개 시점 TBD, thinking 토큰은 K2.6 대비 약 30% 절감으로 문샷이 보고.
- **검증 한계:** SWE-Bench Pro·Terminal-Bench·Aider 등 독립 재현은 6월 12일 시점 미제출·보류.

③ 시사점

Kimi K2.7-Code의 연구·개발상 의미는 절대 성능 1위 주장보다 **오픈웨이트 1T MoE 코딩 에이전트를 실제 배포 가능한 형태로 공개했다는 점**에 있다. 문샷 자체보고 기준으로는 Kimi Code Bench v2와 Program Bench에서 Claude Opus 4.8·GPT-4.5에 못 미치지만, MCP Mark Verified에서는 81.1로 Opus 4.8의 76.4를 앞선다고 제시돼 도구호출 최적화가 별도 경쟁 축으로 분화되고 있음을 시사한다. 개발팀 입장에서는 256K 컨텍스트, 약 30% thinking 토큰 절감, 자가호스팅 가능성이 장기 에이전트 코딩의 비용·통제권·데이터 거버넌스 선택지를 넓힐 수 있다. 정책 관점에서는 중국 오픈모델 진영이 코딩 에이전트 영역에서도 가중치 공개와 저가 접근을 결합하고 있어, 미·중 AI 공급망, 오픈소스 생태계, 공공·기업의 모델 조달 기준에 영향을 줄 수 있다. 다만 현재 성능 주장은 모두 Moonshot AI 자체보고이며, SWE-Bench Pro·Terminal-Bench·Aider 등 널리 비교되는 독립 벤치마크가 아직 제출·재현되지 않았다는 점이 핵심 한계다. 향후 관전 포인트는 독립 재현에서 K2.6 대비 개선폭이 유지되는지, MCP 계열 도구호출 우위가 실제 소프트웨어 리포지터리 작업으로 이어지는지, API 가격과 예고된 6x 고속 모드가 장기 자율 코딩 비용 구조를 얼마나 바꾸는지다.

④ 출처

- Moonshot AI (Hugging Face model card)
- Moonshot AI Releases Kimi K2.7-Code: Reporting +21.8% on Kimi Code Bench v2 Over K2.6 (MarkTechPost)
- Kimi AI releases open-source K2.7 Code model with 1 trillion parameters on APIs and Hugging Face (CryptoBriefing)
- Kimi K2.7-Code: Moonshot's coding-first open-source release (DigitalApplied)
- Google Gemini 3.5 Pro nears June launch — still limited Vertex preview (TechTimes)

그 외 주목 단신

- Google DiffusionGemma 26B-A4B 오픈 확산 모델 공개(6/10)
- Microsoft, 자체 MAI 모델군 7종 공개 — OpenAI 의존 탈피 신호
- OpenAI·Anthropic·Google·Microsoft 수장, 합성 DNA 스크리닝 의무화 의회 공개서한(6/5)