

미 정부, Fable 5·Mythos 5 차단 지시

외국 국적자 접근 제한에 전면 중단

Anthropic

Claude Fable 5

Claude Mythos 5

Commerce Department

Pliny the Liberator

6월 12일 5:21 ET

상무부 지시 수령 시점

2개 모델

Fable 5·Mythos 5 차단 대상

3일

출시 후 전면 중단까지 기간

120,000자

Pliny가 추출 주장한 시스템 프롬프트

한눈에 보기

- Anthropic 공식 성명에 따르면 회사는 2026년 6월 12일 오후 5시 21분(ET) 미 상무부로부터 Claude Fable 5와 Claude Mythos 5에 대해 모든 외국 국적자의 접근을 차단하라는 수출통제 지시를 받았다.
- Anthropic은 국적·시민권을 실시간 선별해 일부만 차단하는 방식이 사실상 불가능하다고 보고, 유료 기업고객·일반 사용자·내부 직원까지 포함해 두 모델 접근을 전면 중단했다고 밝혔다.
- 발단은 6월 10일 Pliny the Liberator가 공개한 Fable 5 가드레일 우회 주장과 경쟁 AI 기업의 상무부 보고다. Pliny는 약 120,000자 시스템 프롬프트 추출을 주장했으나, Anthropic은 보편적 탈옥은 확인되지 않았다는 입장이다.
- 이번 조치는 첨단 반도체·GPU가 아니라 상용 프런티어 AI 모델 자체에 국적 기준 접근통제를 적용한 사례로 제시됐다. 향후 글로벌 AI 서비스 운영과 다국적 연구협업에서 시민권·국적 검증 요구가 쟁점이 될 수 있다.

① 무엇이 달라졌나

Anthropic이 6월 10일 공개한 Claude Fable 5와 Claude Mythos 5가 출시 사흘 만에 전면 중단됐다. 공식 성명에 따르면 미 상무부는 국가안보를 이유로 두 모델을 모든 외국 국적자(미국 내외의 외국인과 외국인 신분 직원 포함)에게 제공하지 말라는 수출통제 지시를 내렸다. 기존 수출통제가 첨단 반도체·GPU 중심이었다는 점에서, 이번 사안은 상용 AI 모델 접근 자체가 통제 대상이 될 수 있음을 보여준다. 기술적으로는 안전 분류기 구조와 탈옥 가능성이, 정책적으로는 단일 기업·모델에 대한 긴급 차단의 근거와 형평성이 동시에 쟁점이다.

② 사실과 쟁점

Anthropic 공식 성명에 따르면 회사는 2026년 6월 12일 금요일 오후 5시 21분(ET) 미 상무부(Commerce Department)로부터 Claude Fable 5와 Claude Mythos 5에 대한 수출통제 지시를 받았다. 지시의 범위는 두 모델에 한정됐지만, 대상은 “모든 외국 국적자(any foreign national)”로 설정됐다. Anthropic은 이 범위가 미국 밖의 외국인뿐 아니라 미국 내 외국인, 외국인 신분의 Anthropic 직원까지 포괄한다고 설명했다. 회사는 지시 서한이 구체적 안보 우려를 상세히 설명하지 않았다고 밝혔다.

Anthropic은 선별 차단이 실무적으로 불가능하다는 이유로 두 모델의 모든 고객 접근을 중단했다. 회사 설명상 문제는 특정 국가나 특정 계정군만 차단하는 것이 아니라, 실시간으로 국적·시민권을 식별하고 모델 인스턴스별 접근권한을 분리해야 한다는 점이다. 그 결과 유료 기업고객, 일반 사용자, 내부 직원까지 포함해 Fable 5와 Mythos 5가 전면 중단됐다. 두 모델은 6월 10일 출시됐고, 같은 날 Pliny the Liberator의 탈옥 주장이 공개된 뒤 6월 12일 정부 지시와 전면 중단으로 이어졌다.

모델 구조 측면에서 Fable 5와 Mythos 5는 동일 기반 모델을 안전 분류기(safety classifier) 계층으로 분기한 두 제품으로 설명된다. Anthropic 설명에 따르면 Mythos 5는 제약이 덜한 고성능 버전이고, 공개용 Fable 5는 사이버보안·생물·화학·모델 디스틸레이션 등 고위험 질의를 더 약한 풀백 모델 Claude Opus 4.8로 우회시키도록 설계됐다. 정부가 위험요소로 지목한 부분은 Mythos 5가 “수십 년간 발견되지 않은 소프트웨어 취약점까지 탐지하는 능력”을 가질 수 있다는 점이다. 다만 이 판단의 세부 근거는 Anthropic 성명 기준으로 공개되지 않았다.



Claude Fable 5·Mythos 5 접근 중단 관련 Anthropic 공식 성명 화면, 출처: Anthropic (공식 성명)

발단이 된 기술 주장은 Pliny the Liberator가 X·GitHub에 공개한 Fable 5 가드레일 우회 시연이다. Pliny는 다중 에이전트 분해(multi-agent decomposition), 유니코드 트릭, 서사적 프레이밍을 조합해 안전 분류기를 우회했으며, 약 120,000자 분량의 시스템 프롬프트를 추출해 GitHub에 공개했다고 주장했다. 시연 영역은 사이버보안, 화학, 심리조작, 폭발물로 제시됐다. 이 주장은 레드팀 성격의 공개 시연이지만, 독립기관이 보편적 탈옥 여부를 검증했다는 정보는 공개되지 않았다.

Anthropic의 반박은 두 갈래다. 첫째, 회사는 **자체 보고**로 1,000시간 이상 버그바운티 테스트를 수행했지만 보편적 탈옥을 발견하지 못했다고 밝혔다. 둘째, 분류기 시스템이 모델과 별도로 작동하기 때문에 ‘대화 거부’ 우회만으로 핵심 안전장치가 해제되는 것은 아니라고 주장했다. Anthropic은 정부 시연이 보여준 능력 수준이 OpenAI GPT-5.5 등 이미 공개 배포된 경쟁 모델에서도 이용 가능한 “널리 가용한” 수준이라고 평가했다. 이 평가는 회사의 주장으로, 공개 정보에는 독립 검증 결과가 제시돼 있지 않다.

정책 쟁점은 조치의 근거와 범위다. Anthropic은 “좁은 범위의 비보편적 탈옥이 수억 명에게 배포된 상용 모델 회수의 근거가 될 수 없다”고 밝혔고, 같은 기준을 업계 전반에 적용하면 “사실상 모든 신규 모델 배포가 중단될 것”이라고 주장했다. 반면 정부 조치는 국가안보와 수출통제 프레임에 따라 내려졌으며, 경쟁 AI 기업이 상무부에 보고한 우회 성공 사례가 발단 중 하나로 제시됐다. 그러나 지시 서한의 구체적 안보 우려, 평가 방법, 단일 기업·모델만을 대상으로 삼은 이유는 공개 정보만으로는 확인하기 어렵다.

- **지시·범위:** 2026년 6월 12일 17:21 ET 미 상무부 수출통제 지시. 대상=Fable 5·Mythos 5와 모든 외국 국적자(미국 내외·외국인 직원 포함).
- **서비스 영향:** 국적·시민권 실시간 선별이 불가능해 전 고객·전 인스턴스 차단으로 대응.
- **탈옥 주장:** Pliny the Liberator가 다중 에이전트 분해·유니코드 트릭·서사적 프레이밍으로 분류기를 우회, 약 120,000자 시스템 프롬프트 추출을 주장.
- **회사 반박:** 자체 보고로 1,000시간+ 버그바운티에서 보편적 탈옥 미발견(독립 검증 전), 문제 능력은 GPT-5.5 등 기존 공개 모델에도 ‘널리 가용’하다고 주장.

③ 왜 중요한가

이번 사안의 핵심은 프런티어 모델의 안전성 논쟁이 곧바로 수출통제 집행으로 연결됐다는 점이다. 정책 관점에서는 ‘모델 가중치 공개’나 ‘칩 수출’이 아니라 상용 폐쇄형 모델 접근권 자체가 국적·시민권 기준의 통제 대상이 될 수 있음을 보여준다. 이 기준이 유지되면 글로벌 AI 서비스 사업자는 계정 단위의 지역 제한을 넘어, 이용자와 직원의 국적·시민권을 확인하고 모델별 접근권한을 실시간 관리해야 하는 운영 부담을 안게 된다. 연구·개발 관점에서는 레드팀 공개 시연의 역할도 복잡해진다. Pliny the Liberator의 탈옥 주장은 안전 취약점을 드러내기 위한 공개 행동으로 볼 수 있지만, 이번 사례에서는 정부 차단 조치의 촉발 요인으로 작용했다. 동시에 Anthropic의 1,000시간 이상 버그바운티 및 보편적 탈옥 부재 주장은 회사 자체 보고이므로, 향후 독립 검증과 재현 가능한 평가 절차가 중요해진다. 관전 포인트는 상무부가 구체적 안보 우려와 평가 기준을 공개할지, Anthropic이 예고한 추가 세부사항과 접근 복구 방안이 어떤 형태가 될지, 그리고 동일 기준이 OpenAI GPT-5.5 등 다른 공개 배포 모델에도 적용될지 여부다.

④ 출처

- Anthropic (공식 성명)
- Anthropic Says US Orders Halt to Foreign Access for Fable 5, Mythos 5 AI Models (Bloomberg)
- Anthropic disables Fable and Mythos AI models after U.S. government bars it from giving foreigners access (Fortune)
- Scoop: Trump admin blocks foreign access to Anthropic's most powerful AI (Axios)
- US orders Anthropic to disable AI models for all foreign nationals (Al Jazeera)
- Anthropic Disputes Fable 5 AI Jailbreak (SecurityWeek)
- Anthropic blocks all public access to Claude Fable 5, Mythos 5 — what enterprises should do (VentureBeat)
- 페이블 5·미소스 5 해외 서비스 중단…미국, 외국인 차단 행정명령 (AIT타임스)
- 42개 주 법무장관, OpenAI 전방위 조사 착수 (TechCrunch·Reuters·Bloomberg)