

미 정부, Fable 5·Mythos 5 외국인 차단

엔트로픽, Fable 5·Mythos 5 접근 전면 중단

Anthropic

Fable 5

Mythos 5

Commerce Department

Pliny the Liberator

5:21pm ET

엔트로픽이 상무부 지시를 받은 시각(2026-06-12)

3일

Fable 5·Mythos 5 출시 후 중단
까지 기간

120,000자

Pliny가 추출했다고 주장한 시스템 프롬프트

1,000시간+

엔트로픽 자체 보고 버그바운티 테스트

KEYNOTE

- 엔트로픽 공식 성명에 따르면 미 상무부는 2026년 6월 12일 오후 5시 21분(ET) Fable 5·Mythos 5에 대해 모든 외국 국적자의 접근을 차단하라는 수출통제 지시를 내렸다.
- 대상은 미국 내외 외국 국적자와 외국인 신분의 엔트로픽 직원까지 포함한다. 엔트로픽은 실시간 국적·시민권 선별이 사실상 불가능해 두 모델을 유료 기업고객·일반 사용자·내부 직원까지 전 세계적으로 중단했다고 밝혔다.
- 발단은 6월 10일 Pliny the Liberator가 공개한 Fable 5 탈옥 주장과 경쟁 AI 기업의 상무부 보고다. Pliny는 다중 에이전트 분해·유니코드 트릭·서사적 프레이밍으로 약 120,000자 시스템 프롬프트를 추출했다고 주장했다.
- 엔트로픽은 1,000시간 이상 버그바운티 테스트에서 보편적 탈옥을 발견하지 못했다는 자체 보고를 근거로 이의를 제기했다. 다만 정부 지시의 구체적 안보 우려는 공식 성명 기준으로 상세히 공개되지 않았다.

① 개요

엔트로픽은 2026년 6월 12일 공식 성명에서 미국 상무부의 수출통제 지시로 Claude Fable 5와 Claude Mythos 5 접근을 전면 중단했다고 밝혔다. 두 모델은 6월 10일 출시됐으나, 외국 국적자 차단 지시와 선별 집행의 기술적 한계 때문에 출시 사흘 만에 전체 고객·직원 대상 중단으로 이어졌다. 이번 사안은 레드팀 탈옥 시연과 경쟁사 보고가 상용 프런티어 모델의 국적 기반 접근 통제에 연결된 사례다. 쟁점은 특정 모델의 안전성뿐 아니라 폐쇄형 모델 자체가 수출통제 대상으로 다뤄질 수 있는지, 그리고 다국적 연구·기업 운영에서 시민권 검증이 어떤 방식으로 요구될지에 있다.

② 주요내용

엔트로픽 공식 성명에 따르면 회사는 2026년 6월 12일 금요일 오후 5시 21분(ET) 미 상무부(Commerce Department)로부터 Claude Fable 5와 Claude Mythos 5에 대한 수출통제 지시를 받았다. 지시 범위는 두 모델에 한정됐지만, 접근 차단 대상은 **모든 외국 국적자(any foreign national)**로 정의됐고 미국 내외 여부를 가리지 않으며 외국인 신분의 엔트로픽 직원까지 포함했다. 엔트로픽은 공식 성명에서 지시 서한이 구체적 안보 우려를 상세히 설명하지 않았다고 밝혔다. 일부 보도에서 특정 장관 명의 서한이 언급됐지만, 엔트로픽 공식 성명은 개인·직위를 명시하지 않았다.

집행 방식은 정책 범위보다 더 넓게 작동했다. 엔트로픽은 이용자의 국적·시민권을 실시간으로 식별해 선별 차단하는 것이 사실상 불가능하다고 보고, 유료 기업고객·일반 사용자·내부 직원까지 포함해 Fable 5와 Mythos 5의 전 모델 인스턴스를 전 세계적으로 중단했다고 설명했다. 두 모델은 6월 10일 출시됐기 때문에, 출시 후 사흘 만에 서비스가 멈춘 셈이다. 이 조치는 특정 국가 또는 특정 고객군에 대한 차단이 아니라, 외국 국적자 접근 금지 지시를 준수하기 위한 전면 중단으로 귀결됐다는 점에서 운영상 파장이 크다.

기술적으로 Fable 5와 Mythos 5는 동일 기반 모델을 안전 분류기(safety classifier) 계층으로 분기한 두 제품으로 설명된다. Mythos 5는 제약이 덜한 고성능 버전이고, 공개용 Fable 5는 사이버보안·생물·화학·모델 디스틸레이션 등 고위험 질의를 더 약한 폴백 모델 Claude Opus 4.8로 우회시키는 구조다. 정부는 Mythos 5가 **수십 년간 발견되지 않은 소프트웨어 취약점까지 탐지하는 능력**을 위험요소로 지목한 것으로 알려졌다. 다만 이 위험평가의 세부 근거와 검증 절차는 엔트로픽 공식 성명 안에서 공개되지 않았다.

사건의 발단은 6월 10일 유명 레드티머 Pliny the Liberator가 X와 GitHub에 공개한 Fable 5 가드레일 우회(jailbreak) 주장이다. Pliny는 다중 에이전트 분해(multi-agent decomposition), 유니코드 트릭, 서사적 프레이밍을 조합해 안전 분류기를 우회했고, 약 120,000자 분량의 시스템 프롬프트를 추출해 GitHub에 공개했다고 주장했다. 시연 영역으로는 사이버보안, 화학, 심리조작, 폭발물이 언급됐다. 또한 경쟁 AI 기업이 상무부에 우회 성공 사례를 보고한 것이 정부 조치의 직접 배경으로 제시됐다.



정부의 외국인 접근 차단 지시로 중단된 엔트로픽 Fable 5·Mythos 5 (보도사진, 출처: Getty Images)

엔트로픽은 이 해석에 이의를 제기했다. 회사는 1,000시간 이상 버그바운티 테스트에서 보편적 탈옥을 발견하지 못했다는 자체 보고를 내세웠고, 분류기 시스템이 모델과 별도로 작동하기 때문에 단순한 대화 거부 우회만으로 핵심 안전장치가 해제되는 것은 아니라고 주장했다. 엔트로픽은 정부 시연이 보여준 능력 수준이 OpenAI GPT-5.5 등 이미 공개 배포된 경쟁 모델에서도 이용 가능한 널리 가용한 수준이라고 평가했다. 회사가 보는 정부 우려의 핵심은 특정 코드베이스를 읽고 결함을 수정하는 좁은 비보편적 탈옥이며, 이를 수억 명에게 배포된 상용 모델 회수의 근거로 삼는 것은 과도하다는 입장이다.

- **지시 시각:** 엔트로픽 공식 성명 기준 2026년 6월 12일 오후 5시 21분(ET), 미 상무부 수출통제 지시.
- **대상 모델:** Claude Fable 5와 Claude Mythos 5. 지시는 두 모델에 한정됐다.
- **차단 대상:** 모든 외국 국적자. 미국 내외 불문이며 외국인 신분의 엔트로픽 직원도 포함된다.
- **출시·중단 타임라인:** 6월 10일 출시, 같은 날 Pliny the Liberator 탈옥 주장 공개, 6월 12일 지시 수령과 전면 중단.
- **모델 분기:** 동일 기반 모델을 안전 분류기 계층으로 나누며, Fable 5는 고위험 질의를 Claude Opus 4.8로 우회시키고 Mythos 5는 제약이 덜한 고성능 버전으로 설명된다.
- **탈옥 주장:** Pliny는 다중 에이전트 분해·유니코드 트릭·서사적 프레이밍을 사용해 약 120,000자 시스템 프롬프트를 추출했다고 주장했다.
- **엔트로픽 반박:** 1,000시간 이상 버그바운티 테스트에서 보편적 탈옥이 발견되지 않았다는 자체 보고를 제시했다. 이 수치는 회사 자체 보고이며 독립 검증 결과로 제시된 것은 아니다.
- **후속 조치:** 엔트로픽은 고객 혼란에 사과하고, 이번 사안을 오해로 보며 접근 복구를 추진하겠다고 밝혔다. 구체 복구 시점은 제시하지 않았고 24시간 내 추가 세부사항 공개를 예고했다.

③ 시사점

이번 사안의 정책적 의미는 상용 폐쇄형 프런티어 모델이 반도체·GPU처럼 수출통제의 직접 대상이 될 수 있음을 보여준 데 있다. 특히 지시 기준이 국가나 조직이 아니라 **외국 국적자**로 설정되면서, 미국 내 외국인 직원·연구자까지 규제 대상에 포함되는 문제가 발생했다. 엔트로픽 사례처럼 실시간 국적·시민권 선별이 어렵다면, 기업은 선별 차단보다 서비스 전체 중단을 선택할 가능성이 커지고, 이는 글로벌 기업고객의 워크로드와 다국적 연구협업에 직접 영향을 준다. 연구·개발 측면에서는 레드팀 탈옥 공개가 취약점 개선 절차로 흡수되기보다 즉각적인 접근 통제에 근거가 될 수 있다는 점이 확인됐지만, Pliny의 주장과 엔트로픽의 반박 사이에서 보편적 탈옥 여부는 공개 자료만으로 확정하기 어렵다. 한계도 분명하다. 정부 지시 서한의 구체 안보 우려와 평가 기준은 엔트로픽 공식 성명 기준으로 공개되지 않았고, 엔트로픽의 1,000시간 이상 버그바운티 테스트 결과 역시 자체 보고로서 독립 검증 전 수치다. 향후 관전 포인트는 상무부가 두 모델에 한정된 조치를 유지할지, 국적·시민권 검증 의무가 다른 프런티어 모델과 동맹국 이용자에게 확대될지, 그리고 동등 능력이 GPT-5.5 등에도 있다는 엔트로픽의 형평성 주장이 정책 판단에 반영될지다.

④ 출처

- Anthropic (공식 성명)
- Anthropic Says US Orders Halt to Foreign Access for Fable 5, Mythos 5 AI Models (Bloomberg)
- Anthropic disables Fable and Mythos AI models after U.S. government bars it from giving foreigners access (Fortune)
- Scoop: Trump admin blocks foreign access to Anthropic's most powerful AI (Axios)
- US orders Anthropic to disable AI models for all foreign nationals (Al Jazeera)
- Anthropic Disputes Fable 5 AI Jailbreak (SecurityWeek)
- Anthropic blocks all public access to Claude Fable 5, Mythos 5 — what enterprises should do (VentureBeat)
- 페이블 5·미소스 5 해외 서비스 중단…미국, 외국인 차단 행정명령 (AIT타임스)
- 42개 주 법무장관, OpenAI 전방위 조사 착수 (TechCrunch·Reuters·Bloomberg)

그 외 주목 단신

- 엔비디아, 차세대 '베라(Vera)' CPU로 중국 공략 — GPU 규제 우회 (8월 출시·유닛 \$2만+)
- 샤오미, 오픈소스 코딩 에이전트 '미모 코드(MiMo Code)' 공개 — SWE-Bench Verified 82% 주장
- '메모리' 키옥시아, 도요타 제치고 일본 시총 1위 — 올해 670% 폭등(AI 메모리 수요)