

구글 딥마인드, DiffusionGemma 공개

확산식 생성으로 H100 1,000+ tok/s 자체보고

Google DeepMind

DiffusionGemma

Gemma 4

Hugging Face

NVIDIA

1,100+ tok/s

H100 FP8 저배치 생성 속도, 모델카드 자체보고

700+ tok/s

RTX 5090 생성 속도, Google DeepMind 자체보고

25.2B / 3.8B

총 파라미터 / 추론 시 활성 파라미터

77.6% vs 82.6%

MMLU Pro, DiffusionGemma vs Gemma 4 자체보고

한눈에 보기

- Google DeepMind는 2026년 6월 10일 이산 텍스트 확산 방식의 오픈 가중치 모델 DiffusionGemma를 Apache 2.0 라이선스로 공개했다. 가중치는 Hugging Face·Kaggle·Google Cloud Vertex AI에 배포됐다.
- DiffusionGemma는 256토큰 캔버스를 병렬 디노이징하는 구조를 쓰지만, 공식 모델카드는 한 forward pass에서 실제 확정되는 토큰을 15~20개로 구분해 적고 있다. 이 차이는 '256토큰을 매 패스 완성한다'는 식의 해석을 피해야 하는 핵심 사양이다.
- 속도는 Google DeepMind 자체보고 기준 H100에서 1,000+ tok/s, 모델카드 기준 H100 FP8 저배치 1,100+ tok/s, RTX 5090에서 700+ tok/s다. NVIDIA 블로그는 DGX Spark 150 tok/s, DGX Station 최대 2,000 tok/s도 제시했다.
- 품질 지표는 표준 Gemma 4보다 낮다. Google DeepMind 모델카드 자체보고에서 DiffusionGemma는 MMLU Pro 77.6%, GPQA Diamond 73.2%, AIME 2026(no tools) 69.1%로, 비교값인 Gemma 4의 82.6%, 82.3%, 88.3%에 못 미쳤다.

① 무엇이 달라졌나

Google DeepMind가 공개한 DiffusionGemma는 기존 LLM의 왼쪽-오른쪽 순차 디코딩 대신, 블록 단위 텍스트를 확산 방식으로 병렬 디노이징해 생성하는 실험적 오픈 가중치 모델이다. 변화의 핵심은 모델 품질을 끌어올리는 발표가 아니라, 자기회귀 디코딩의 메모리 대역폭 병목을 줄이고 지연시간을 낮추려는 생성 방식의 전환이다. 모델은 Gemma 4 계열 26B MoE 기반이며, 추론 시 3.8B 파라미터만 활성화한다. 다만 Google DeepMind는 출력 품질이 표준 Gemma 4보다 낮다고 명시했고, 최고 품질이 필요한 용도에는 Gemma 4를 권고했다.

MMLU Pro — DiffusionGemma와 Gemma 4

% · 높을수록 우수 · Google DeepMind 모델카드 자체보고

DiffusionGemma

77.6

Gemma 4

82.6

② 사실과 쟁점

Google DeepMind는 2026년 6월 10일 공식 블로그와 모델카드를 통해 DiffusionGemma를 공개했다. 이 모델은 텍스트를 한 토큰씩 순차 생성하는 자기회귀 방식이 아니라, **이산 텍스트 확산(discrete text diffusion)**과 **block-autoregressive 멀티캔버스 샘플링**을 결합한다. Google DeepMind 설명에 따르면 256토큰 단위의 '캔버스'를 병렬로 디노이징하며, 캔버스 내부에서는 양방향 어텐션으로 모든 토큰이 서로를 참조한다. 다만 공식 모델카드는 캔버스 길이 256토큰과 별도로, 한 forward pass에서 실제 확정되는 토큰 수를 **15~20 tokens**로 적고 있다. 따라서 '256토큰 병렬'은 처리 폭을 뜻하며, 매 패스 256토큰이 모두 커밋된다는 의미로 해석하면 안 된다.

아키텍처는 Gemma 4 계열의 26B Mixture-of-Experts 구조다. 공식 모델카드는 총 파라미터를 **25.2B**로, 추론 시 활성 파라미터를 **3.8B**로 제시한다. 전문가 구성은 **8 active / 128 total + 1 shared**이며, 비전 인코더는 약 **550M**

규모다. 입력은 텍스트·이미지를 지원하고 영상 처리도 지원하며, 출력은 텍스트다. 모델카드 기준 컨텍스트는 최대 **256K 토큰**, 사전학습 언어는 **140+ 언어**, 데이터 컷오프는 **2025-01**이다. 또한 <[think]> 토큰을 사용하는 'thinking' 모드를 지원한다고 제시됐다.

속도 수치는 모두 회사 및 관련 공급사 발표값으로, 독립 벤치마크로 확정된 값은 아니다. Google DeepMind 블로그는 DiffusionGemma가 단일 NVIDIA H100에서 **1,000+ tok/s**, RTX 5090에서 **700+ tok/s**를 낸다고 밝혔다. 공식 모델카드는 H100 FP8 저배치 조건에서 **1,100+ tok/s**를 제시했다. NVIDIA 블로그는 H100 **1,000 tok/s**, DGX Spark **150 tok/s**, DGX Station **최대 2,000 tok/s**를 언급하고, 자기회귀 동급 모델 대비 약 **4배** 빠르다고 설명했다. 이 수치들은 DiffusionGemma가 디코딩 병목을 메모리 대역폭 중심에서 연산 중심으로 옮기려는 설계라는 Google DeepMind의 설명과 연결된다.

배포 측면에서는 Apache 2.0 라이선스의 오픈 가중치 모델로 제공됐다. 가중치는 Hugging Face, Kaggle, Google Cloud Vertex AI에 공개됐으며, 2026년 6월 15일 기준 Hugging Face 트렌딩 모델 1위로 기록됐다. 지원 프레임워크로는 Transformers, vLLM(day-zero), SGLang, MLX, Unsloth 파인튜닝, NVIDIA NeMo, Docker Model Runner가 제시됐다. 양자화는 NVFP4 등 4-bit float 계열을 포함하며, 블로그는 양자화 시 **18GB VRAM** 내 구동을 언급했다. 모델카드 및 배포 설명 맥락에서는 RTX 5090·4090의 **24GB VRAM** 환경도 제시돼, 로컬 추론과 소비자 GPU 실험을 염두에 둔 릴리스로 볼 수 있다.

품질 벤치마크는 속도와 다른 방향의 신호를 준다. Google DeepMind 모델카드 자체보고에서 DiffusionGemma는 표준 Gemma 4보다 모든 제시 항목에서 낮았다. 회사도 블로그에서 속도와 병렬 레이아웃 생성을 우선했기 때문에 출력 품질이 표준 Gemma 4보다 낮고, 최고 품질이 필요한 용도에는 Gemma 4를 권고한다고 밝혔다. 따라서 이번 공개는 'Gemma 4의 상위 품질 모델'이라기보다, 다른 생성 패러다임을 대규모 오픈 가중치 모델로 실험할 수 있게 한 사례로 해석하는 편이 정확하다.

쟁점은 세 가지다. 첫째, 속도 수치와 벤치마크는 Google DeepMind 및 NVIDIA 발표값이므로, 실제 워크로드·배치·프롬프트 길이·양자화 조건에서 독립 재현이 필요하다. 둘째, 캔버스 병렬성은 개발자 경험상 지연시간을 낮출 수 있지만, 모델카드가 밝힌 패스당 확정 토큰 15~20개라는 제약 때문에 응용별 체감 성능은 샘플링 정책에 좌우될 수 있다. 셋째, 품질 지표가 표준 Gemma 4보다 낮기 때문에, 에이전트 루프·온디바이스 비서·대화형 인터페이스처럼 지연시간이 우선인 용도와, 고난도 추론·수학·코딩처럼 정확도가 우선인 용도의 선택 기준이 분리될 가능성이 크다.

③ 왜 중요한가

연구·개발 관점에서 DiffusionGemma의 의미는 텍스트 확산 모델을 논문 수준의 아이디어가 아니라 25.2B MoE, 멀티모달 입력, 256K 컨텍스트, Apache 2.0 오픈 가중치 형태로 실험할 수 있게 했다는 점이다. 자기회귀 LLM의 순차 디코딩은 토큰 단위 의존성 때문에 지연시간과 메모리 대역폭의 영향을 크게 받는데, DiffusionGemma는 256토큰 캔버스와 병렬 디노이징으로 이 병목을 다른 방식으로 재배치한다. 이는 모델 품질 경쟁보다 추론 효율, 로컬 실행, 단일 사용자 에이전트 루프의 응답성을 연구하는 쪽에 직접적인 실험 대상을 제공한다. 다만 Google DeepMind 자체보고 벤치마크에서 MMLU Pro, GPQA Diamond, MATH-Vision, LiveCodeBench v6, AIME 2026 모두 Gemma 4보다 낮았으므로, 현재 단계에서 확산식 생성이 품질 면에서 자기회귀 표준을 대체한다고 결론낼 근거는 부족하다. 향후 관련 포인트는 독립 벤치마크에서 1,000+ tok/s급 속도가 어떤 조건에서 재현되는지, 15~20개 패스당 확정 토큰 정책이 긴 생성·코딩·에이전트 작업에서 어떤 오류 양상을 만드는지, 그리고 품질 저하 없이 캔버스 병렬성을 키울 수 있는 학습·샘플링 기법이 나오는지다.

④ 출처

- Google DeepMind: DiffusionGemma 공식 블로그 (패러다임·속도)
- DiffusionGemma model card (공식 사양·벤치마크)
- DiffusionGemma 모델 카드 (Hugging Face)
- NVIDIA Accelerates Google DeepMind's DiffusionGemma for Local AI

그 외 주목 단신

- MiniMax Sparse Attention(MSA): 1M 컨텍스트 어텐션 28.4배 절감
- NVIDIA Blackwell, 첫 에이전트 인프라 벤치마크 AgentPerf 1위
- 앤스로픽 Fable 5·Mythos 5 수출통제 — 아마존 제보가 발단(후속)