

Z.ai, GLM-5.2 오픈웨이트 공개

1M 컨텍스트·MIT 라이선스

- Z.ai
- GLM-5.2
- IndexShare
- GLM-5.1
- GPT-5.5

1M 지원 컨텍스트 길이	2.9× 1M 컨텍스트 토큰당 FLOPs 절감, Z.ai 자체 보고	62.1 SWE-bench Pro, Z.ai 자체 보고	\$1.4/\$4.4 입력/출력 100만 토큰 API 가격, Agent Arena 표기
-------------------------------------	---	--	--

한눈에 보기

- Z.ai는 2026년 6월 16~17일 GLM-5.2를 HuggingFace에 MIT 라이선스 오픈웨이트로 공개했다. 모델카드는 1M 토큰 컨텍스트와 장기 과제 수행을 핵심 목표로 제시한다.
- Z.ai 자체 보고에 따르면 GLM-5.2는 SWE-bench Pro 62.1로 전작 GLM-5.1의 58.4를 앞섰고, Terminal-Bench 2.1은 81.0 대 62.0으로 상승했다. 다만 주요 성능 수치는 독립 검증 전이다.
- 아키텍처 측면에서는 IndexShare가 핵심이다. Z.ai는 4개 sparse attention 레이어마다 동일 indexer를 재사용해 1M 컨텍스트에서 토큰당 FLOPs를 2.9배 줄였다고 보고했다.
- 외신은 SWE-bench Pro에서 GPT-5.5 58.6보다 높은 62.1, FrontierSWE에서 GPT-5.5 72.6%보다 높은 74.4%를 강조했지만, 이 비교 역시 독립 재현이 확인된 결과는 아니다.

① 무엇이 달라졌나

GLM-5.2는 Z.ai가 전작 GLM-5.1 이후 공개한 플래그십 오픈웨이트 대형언어모델로, 긴 컨텍스트와 장기 코딩·에이전트 과제에 초점을 맞춘 릴리스다. 변화의 중심은 1M 토큰 컨텍스트를 전면에 내세운 점과, IndexShare로 긴 컨텍스트 추론 비용을 줄였다는 자체 보고다. 공개 방식은 MIT 라이선스 오픈웨이트로, 상업적 활용과 로컬 실행 가능성을 명시했다. 동시에 벤치마크 비교와 파라미터 규모 표기에는 출처 간 불일치와 독립 검증 공백이 있어, 성능 주장은 재현성 확인이 필요하다.

SWE-bench Pro — 에이전트 코딩 성능


점수 · 높을수록 우수 · GLM 수치는 Z.ai 자체 보고, GPT-5.5는 외신 보도 기준



② 사실과 쟁점

Z.ai는 HuggingFace의 zai-org 계정 모델카드를 통해 **GLM-5.2**를 공개했다. dossier 기준 공개와 트렌딩은 2026년 6월 16~17일에 해당하며, 모델카드에는 arXiv 번호 2602.15763에 기반한 “February 2026” 표기도 함께 나타난다. 따라서 이번 브리프에서의 신선도는 오픈웨이트 공개 시점인 6월을 기준으로 해석하는 것이 적절하다. 공개 직후 HuggingFace 트렌딩 상위에 올랐고 좋아요 수는 약 981로 제시됐다.

모델 사양에서 가장 큰 특징은 **1M, 즉 100만 토큰 컨텍스트**다. Z.ai는 이를 “안정적 1M 컨텍스트”로 강조하면서 장기 과제(long-horizon) 수행을 목표로 제시했다. 총 파라미터 수는 출처 간 표기가 일치하지 않는다. HuggingFace 모델카드 본문에는 753B로, 외신 요약에는 744B로 적혀 있으며, 외신은 MoE 구조에서 토큰당 활성 파라미터를 약 40B로 설명했다. 이 때문에 모델 규모를 인용할 때는 753B와 744B 표기 불일치를 함께 명시해야 한다.



GLM-5.2 벤치마크 요약 차트 (출처: Z.ai GLM-5 공식 GitHub 리소스, 자체 보고치)

아키텍처 측면의 핵심은 **IndexShare**다. dossier에 따르면 IndexShare는 4개 sparse attention 레이어마다 동일 indexer를 재사용하는 방식이며, Z.ai는 이 설계가 1M 컨텍스트에서 토큰당 FLOPs를 2.9배 절감한다고 자체 보고했다. 또한 speculative decoding과 관련해 MTP 레이어를 개선했고, Z.ai는 수용 길이(acceptance length)가 최대 20% 증가했다고 밝혔다. 두 수치 모두 회사 자체 보고치이며, 실제 배포 환경에서의 처리량·지연시간·메모리 사용량으로 독립 재현됐다는 근거는 dossier에 없다.

벤치마크는 전작 GLM-5.1 대비 개선을 전면에 내세운다. Z.ai 자체 보고 기준으로 GLM-5.2는 HLE 40.5 대 31, HLE(도구사용) 54.7 대 52.3, SWE-bench Pro 62.1 대 58.4, MCP-Atlas(Public) 76.8 대 71.8, AIME 2026 99.2 대 95.3, Terminal-Bench 2.1 81.0 대 62.0을 기록했다. 이 수치들은 같은 회사가 제시한 전작 비교라는 점에서 모델 세대 간 방향성을 보여주지만, 평가 설정과 실행 조건이 외부에서 재현됐는지는 별도 확인이 필요하다.

외신 보도는 폐쇄형 프런티어 모델과의 비교를 더 강하게 부각했다. 보도 기준으로 GLM-5.2는 SWE-bench Pro에서 62.1을 기록해 GPT-5.5의 58.6을 앞섰고, FrontierSWE 장기과제에서는 74.4%로 GPT-5.5의 72.6%를 상회하며 Claude Opus 4.8의 75.1%에 근접한 것으로 전해졌다. 또 FrontierSWE 종합 순위는 Fable 5와 Opus 4.8 뒤, GPT-5.5 앞인 3위로 소개됐고, Design Arena에서는 Elo 1360으로 1위라고 보도됐다. 그러나 이 비교값은 외신과 회사 발표 기반의 정리이며, dossier상 독립 검증 결과로 확인되지는 않는다.

접근성과 비용 측면에서는 MIT 라이선스 오픈웨이트라는 점이 중요하다. MIT 라이선스는 상업적 활용과 로컬 실행 가능성을 열어두는 조건으로 제시됐으며, Z.ai는 SGLang(v0.5.13.post1+), vLLM(v0.23.0+), Transformers, KTransformers를 지원한다고 밝혔다. 또한 Ascend NPU 환경에서는 vLLM-Ascend, xLLM, SGLang 지원이 언급됐다. API 가격은 Agent Arena 표기 기준 입력 100만 토큰당 1.4달러, 출력 100만 토큰당 4.4달러로 제시됐고, 이는 GLM-5.1과 동일하며 폐쇄형 대비 대략 1/6 수준이라는 보도가 있다. 이 '1/6' 비교 역시 어떤 폐쇄형 모델·사용량 조합을 기준으로 했는지 dossier만으로는 세부 조건을 확정할 수 없다.

쟁점은 세 가지로 정리된다. 첫째, 대부분의 핵심 성능 수치가 Z.ai 자체 보고 또는 외신 보도 기반이어서 독립 평가기관의 재현 결과와 구분해야 한다. 둘째, 1M 컨텍스트가 실제 장기 코딩·에이전트 작업에서 어느 정도의 정확도 유지, 비용, 지연시간으로 이어지는지는 벤치마크 점수만으로 판단하기 어렵다. 셋째, 오픈웨이트를 로컬에서 실행하는 경우와 중국 제공사 API를 사용하는 경우의 리스크가 다르다. 특히 API 사용은 데이터 거버넌스와 관할권 이슈가 제기됐으며, 기업·공공 부문 도입에서는 배포 방식 선택이 성능만큼 중요한 검토 항목이 된다.

③ 왜 중요한가

연구·개발 관점에서 GLM-5.2의 의미는 오픈웨이트 모델이 긴 컨텍스트, MoE, sparse attention 최적화, speculative decoding 개선을 결합해 프런티어 코딩·에이전트 벤치마크를 겨냥하고 있다는 점이다. MIT 라이선스와 SGLang, vLLM, Transformers, KTransformers, Ascend NPU 지원은 연구자가 폐쇄형 API에만 의존하지 않고 로컬 또는 자체 인프라에서 장기 컨텍스트 실험을 수행할 여지를 넓힌다. 다만 2.9배 FLOPs 절감, 최대 20% acceptance length 증가, SWE-bench Pro 62.1 등 핵심 수치는 Z.ai 자체 보고 또는 외신 보도 기준이므로, 실제 판단에는 동일 프롬프트·동일 도구·동일 에이전트 루프에서의 재현 평가가 필요하다. 정책·도입 관점에서는 오픈웨이트와 API 사용을 분리해 봐야 한다. 로컬 실행은 데이터 반출을 줄일 수 있지만, 중국 제공사 API를 쓰면 데이터 관할권·거버넌스 리스크가 남는다. 관련 포인트는 753B·744B 표기 불일치 해소, 주요 벤치마크의 독립 재현, 그리고 '1/6 비용' 주장의 조건 공개다.

④ 출처

- Z.ai (zai-org)
- AINews: GLM-5.2 — the top Frontend Coding model in the world, IndexShare for Speculative Decoding (Latent Space)
- GLM-5.2 Open Weights Live: Top Coding Benchmark, but API Use Carries China Data Risk (TechTimes)
- Z.ai's new 753B-parameter GLM-5.2 outperforms OpenAI's GPT-5.5 on long-horizon coding tasks while costing six times less per token

그 외 주목 단신

- 구글 리서치, 의료 AI 'AMIE'의 만성질환 관리 능력 Nature 발표 — 1차진료의 21명 맹검 비교서 치료계획 정밀성 우위
- LoopCoder-v2: '한 번만 루프'로 테스트타임 연산 효율화 — SWE-bench Verified 43.0→64.4 (HF Daily Papers 1위)
- 엔비디아, 베라루빈용 HBM4 공급사로 SK하이닉스·삼성·마이크론 인증 — 한국 메모리 양사 AI 인프라 부품 장악