

오픈AI·브로드컴 첫 자체 추론칩 '할라페뇨' 공개

9개월 테이프아웃·비용 50% 절감 주장(자체보고·독립검증 전)

OpenAI

Broadcom

Jalapeño

HBM3e

Nvidia

9개월

초기 설계→테이프아웃 기간

약 50%

기존 AI GPU 대비 비용 절감(자체 보고·미검증)

10GW

OpenAI·Broadcom 커스텀 가속기 협력 규모

2026년 말

양산 시스템 첫 배치 목표

한눈에 보기


- OpenAI와 Broadcom은 2026년 6월 24일 LLM 추론 전용 커스텀 ASIC '할라페뇨(Jalapeño)'를 공개했다. 2025년 10월 발표한 10GW 커스텀 가속기 공동개발·배치 협력의 첫 결과물이다.
- 양사는 초기 설계부터 테이프아웃까지 약 9개월이 걸렸다고 밝혔다. OpenAI는 자사 모델을 설계 작업 가속에 활용했다고 설명했지만, 상세 기술 보고서는 아직 공개하지 않았다.
- Broadcom CEO는 기존 AI GPU 대비 약 50% 비용 절감을, OpenAI 하드웨어 책임자는 전력당 성능이 최고 수준을 크게 상회한다고 밝혔으나, 두 수치 모두 자체 보고로 표준 벤치마크·독립 검증은 아직 없다.
- Jalapeño는 사전학습 대체가 아니라 실서비스 추론 비용·공급 구조를 겨냥한 칩으로, OpenAI는 사전학습·실험엔 Nvidia 하드웨어를 계속 쓴다.

① 무엇이 달라졌나

OpenAI가 Broadcom과 공동 설계한 첫 자체 AI 추론칩 Jalapeño를 공개하면서, 모델 개발사에서 대규모 추론 인프라 설계자로 역할을 넓히는 흐름이 구체화됐다. 이번 칩은 사전학습용 범용 GPU가 아니라 학습된 LLM을 서비스 환경에서 구동하는 추론에 맞춘 커스텀 ASIC이다. 양사는 HBM3e 통합과 연산·메모리·네트워킹 정합을 강조했고, 관련 보도는 Broadcom 네트워킹 구성도 언급했지만, 공정 노드·정확한 처리량·표준 벤치마크는 공개하지 않았다. 따라서 현재 확인되는 변화는 'Nvidia 대체'라기보다 OpenAI가 추론 비용과 공급망을 일부 자체화하려는 다세대 컴퓨트 플랫폼의 첫 단계로 보는 편이 적절하다.

② 사실과 쟁점

OpenAI와 Broadcom의 2026년 6월 24일 공식 발표에 따르면, **Jalapeño**는 LLM 서빙, 특히 실시간 코딩 모델 같은 추론 워크로드를 목표로 한 커스텀 ASIC이다. 발표는 이를 사전학습(training)용 칩이 아니라 학습된 모델을 실서비스에서 구동하는 **추론(inference) 특화 프로세서**로 설명한다. OpenAI 하드웨어 책임자 리처드 호(Richard Ho)는 초기 테스트에서 전력당 성능이 "현존 최고 수준(state-of-the-art)을 크게 상회"한다고 밝혔고, Broadcom CEO 호크 탄(Hock Tan)은 기존 AI GPU 대비 약 50%의 비용 절감을 주장했다. 다만 두 주장은 모두 기업 자체 보고이며, 비교 기준·측정 조건·표준화된 벤치마크 수치는 아직 공개되지 않았다.



Jalapeño 추론 프로세서 공개 발표 이미지.
출처: OpenAI / Broadcom (TechCrunch 게재)

칩 구조와 사양은 일부만 공개됐다. 관련 보도에 따르면 Jalapeño는 레티클급(reticle-sized) 대형 다이의 LLM 추론 전용 ASIC이며, 하나의 큰 컴퓨트 칩렛과 6개 HBM 스택 구성이 언급됐다. 이 정보는 2차 보도 기반이며, 정밀 사양은 양사 공식 문서에서 확정적으로 제시되지 않았다. OpenAI는 HBM3e 스택을 직접 통합해 토큰 생성 속도와 추론 처리량에 맞췄고, 불필요한 데이터 이동을 줄이며 연산·메모리·네트워킹 자원을 더 잘 맞추는 설계 철학을 적용했다고 설명했다.

제조·시스템 구성도 공급망 다변화의 성격을 보인다. 2차 보도에 따르면 파운드리에는 TSMC가 맡고, 실리콘 구현과 네트워킹은 Broadcom이 담당하며, Broadcom Tomahawk 네트워킹 실리콘이 대규모 연결에 쓰인다. 보드·랙·시스템 통합은 Celestica(셀레스티카)가 담당하는 것으로 보도됐다. 구체 공정 노드는 공개되지 않았고, 패키징 세부사항도 공식적으로 확정된 수준의 수치가 제시되지는 않았다.

개발 속도는 이번 발표의 핵심 주장 중 하나다. Broadcom 보도자료와 관련 발표에 따르면 Jalapeño는 초기 설계에서 테이프아웃까지 약 9개월이 걸렸고, OpenAI는 자사 모델을 설계 작업 가속에 활용했다고 밝혔다. 이는 고성능 첨단 반도체에서 매우

짧은 ASIC 개발 사이클로 제시됐지만, "역대 최단" 수준이라는 평가는 자체 주장과 해설에 의존한다. 엔지니어링 샘플은 이미 OpenAI 사내 랩에서 목표 생산 주파수와 전력으로 ML 워크로드를 실행 중이라고 발표했다.

배치 계획은 2025년 10월 13일 발표된 OpenAI·Broadcom의 10GW 커스텀 가속기 공동개발 협력과 연결된다. 당시 양사는 OpenAI 설계 가속기를 Broadcom과 공동개발·배치하고, 2026년 하반기 시작해 2029년 완료하는 목표를 제시했다. 이번 Jalapeño는 그 협력의 첫 산물로 설명되며, 양산 시스템 배치는 2026년 말부터 시작해 기가와트급으로 확장할 계획이다. OpenAI는 이를 다세대(multi-generation) 컴퓨트 플랫폼의 첫걸음이라고 표현했고, 차세대 칩은 2028년 계획으로 언급됐다.

성능·비용 주장의 해석에는 주의가 필요하다. 호크 탄의 "기존 AI GPU 대비 약 50% 비용 절감"은 비교 대상 GPU, 데이터센터 전력·냉각·네트워크 비용 포함 여부, 활용률, 모델 크기, 배치 크기 같은 조건이 공개되지 않았다. 리처드 호의 전력당 성능 우위 주장도 표준화된 벤치마크가 없기 때문에 동일 워크로드에서 재현 가능한 비교로 보기는 어렵다. 테스트 모델로 GPT-5.3-Codex-Spark 등이 언급됐고 "모든 LLM과 호환"되도록 설계됐다는 보도가 있으나, 이 역시 2차 보도 기반이며 공개 검증된 호환성 매트릭스는 아니다.

- **용도:** LLM 추론 전용 커스텀 ASIC. 사전학습용 GPU 대체가 아니라 서비스 추론 비용·처리량 최적화가 목표다.
- **메모리:** HBM3e 스택 직접 통합을 통해 토큰 생성 속도와 데이터 이동 감소를 겨냥했다고 OpenAI가 설명했다.
- **성능 주장:** 전력당 성능이 현존 최고 수준을 크게 상회한다는 OpenAI 자체 보고가 있으나, 표준 벤치마크는 미공개다.
- **비용 주장:** 기존 AI GPU 대비 약 50% 비용 절감은 Broadcom CEO 발언이며, 비교 조건과 독립 검증은 아직 없다.
- **개발 기간:** 초기 설계부터 테이프아웃까지 약 9개월이라고 양사가 밝혔다. OpenAI는 자사 모델로 설계 작업을 가속했다고 설명했다.
- **배치:** 2026년 말 양산 시스템 첫 배치 후 기가와트급 확장을 계획한다. 10GW 협력은 2026년 하반기 시작~2029년 완료가 기존 목표였다.

쟁점은 공개 수준과 검증 가능성이다. Jalapeño가 추론 총소유비용을 얼마나 낮추는지는 칩 단가만으로 판단할 수 없고, HBM 공급·패키징·랙 전력·네트워크·소프트웨어 스택 활용률까지 함께 봐야 한다. 또한 OpenAI가 자체 모델로 칩 설계를 가속했다는 설명은 AI 기반 반도체 설계의 중요한 사례가 될 수 있지만, 어떤 설계 단계에서 어느 정도 기여했는지는 공개되지 않았다. 따라서 현재로서는 "추론 인프라 자체화의 시작"은 확인된 사실이지만, "GPU 대비 우월한 경제성"은 독립 검증 전 주장으로 남아 있다.

③ 왜 중요한가

정책·산업 관점이 핵심이다. 10GW 규모의 커스텀 가속기 협력에서 나온 첫 칩이 추론 영역을 겨냥했다는 점은, 빅테크(구글 TPU·아마존 트레이니움·MS 마이아)에 이어 OpenAI까지 자체 추론칩 대열에 합류해 AI 가속기 시장이 'Nvidia 단일 의존'에서 '추론은 커스텀 ASIC, 사전학습은 Nvidia'로 분화하는 흐름을 보여준다. 한국 공급망 관점에서는, 추론 ASIC도 HBM3e를 다수 스택 탑재하므로 SK하이닉스·삼성전자 등 HBM 공급사에 'Nvidia 외 신규 대형 고객'이 생기고 TSMC 급 파운드리·어드밴스드 패키징 수요도 확대될 수 있다. 단, 이번 발표는 특정 한국 메모리사 채택을 명시하지 않아 국내 공급망 효과는 아직 추정 수준이다(미확인). 기술 관점에서 Jalapeño는 LLM 경쟁이 모델 파라미터·학습 데이터를 넘어 추론 하드웨어·메모리·네트워크 공동설계로 이동하고 있음을 보여주며, HBM3e·대형 ASIC·Broadcom Tomahawk 네트워크의 동시 강조는 토큰 생성 비용에서 데이터 이동과 랙 규모 연결이 핵심 최적화 대상으로 부상했음을 시사한다. 향후 관전 포인트는 표준 벤치마크·전력당 토큰 처리량 공개, '50% 비용 절감'의 산정 기준, 그리고 2026년 말 양산 배치가 10GW 계획으로 얼마나 빠르게 확장되는지다.

④ 출처

- [OpenAI / Broadcom — Jalapeño inference chip \(공식 발표\)](#)
- [OpenAI unveils its first custom chip, built by Broadcom](#)
- [OpenAI and Broadcom Unveil LLM-Optimized Intelligence Processor](#)
- [Broadcom and OpenAI unveil custom-built Jalapeño inference processor](#)
- [OpenAI and Broadcom announce strategic collaboration to deploy 10 gigawatts of AI accelerators \(2025-10-13\)](#)

그 외 주목 단신

- 구글 제미니이 핵심 연구자들 잇따라 앤스로픽을 AI 인재 쟁탈전 격화
- 중국, 2950억달러 '국가 AI 컴퓨팅망'에 국산칩 80% 의무화